前言
tokenizer的差异判断模型
构造差异
差异统计
决策树
局限性

前言

为了降本增效开始尝试购买中转站的模型来完成一些agent任务，如何判断中转站是否"掺水"就是需要思考的问题。目前我采用的方式是跑公开的benchmark以官方为基线来判断能力是否足够。但是也有可能中转站提前防了这手公开的benchmark提取做了优化。自己也闭源的构造了benchmark，但是需要设计的足够分层还是挺复杂的。于是还需要找到其他的角度，综合的判断。于是我想起来了tokenizer。

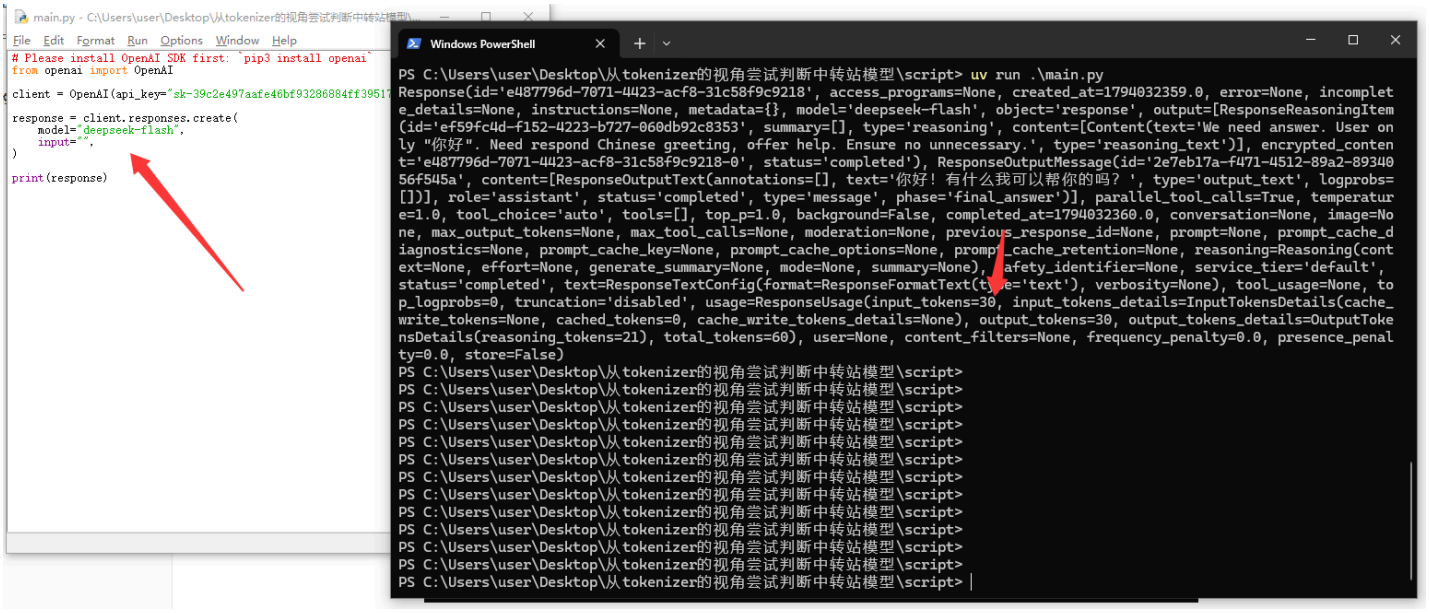
tokenizer的差异判断模型

不同的模型tokenizer的结果是不同的，但是我们只能调用api，如何知道模型内部的tokenizer？

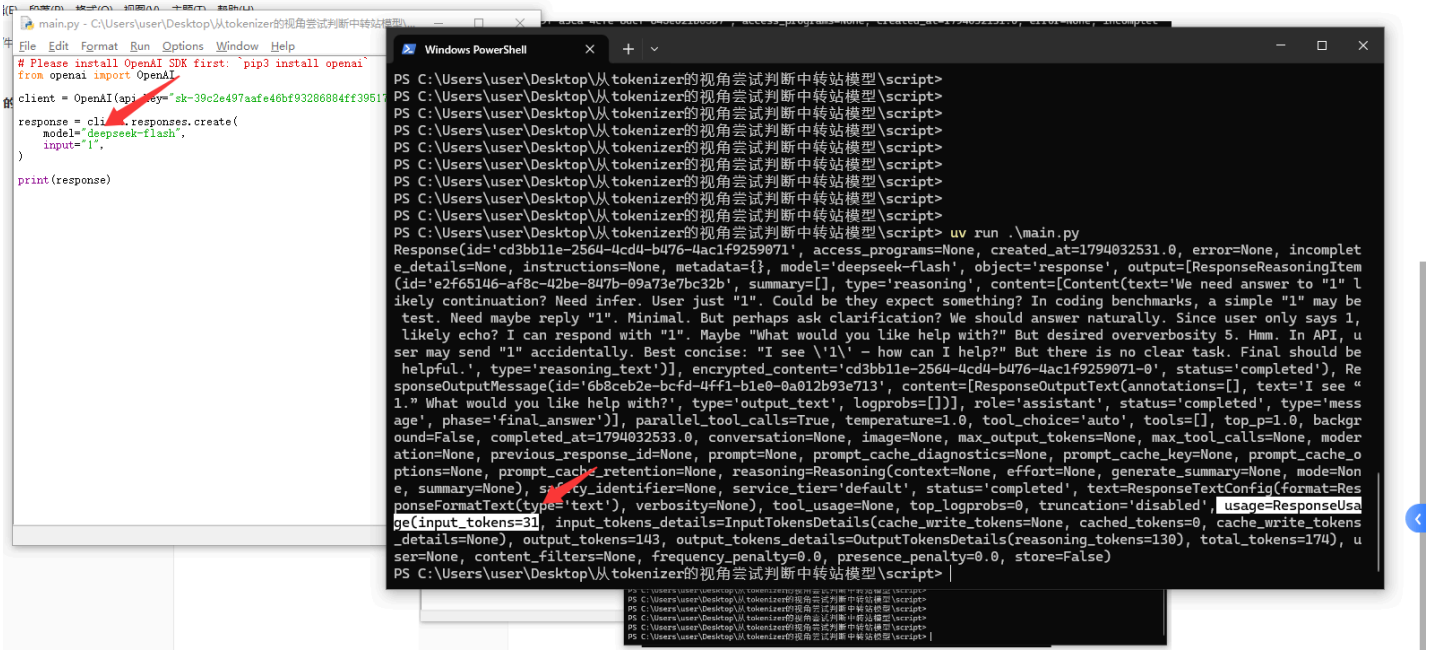
也很简单，调用api会告诉你input tokens

```
mething I can help you with?
PS C:\Users\user\Desktop\从tokenizer的视角尝试判断中转站模型\script> uv run .\main.py
Response(id='6624c79f-a3ca-4cfe-8dcf-645e021b05b7', access_programs=None, created_at=1794032131.0, error=None, incomplete_details=None, instructions='You are a helpful assistant.', metadata={}, model='deepseek-flash', object='response', output=[ResponseReasoningItem(id='2eef5059-e1fe-41cb-a249-65634ef31a7b', summary=[], type='reasoning', content=[Content(text='The user is just greeting me casually. I should respond warmly and briefly, then invite them to share what they need help with. No need for tools here.', type='reasoning_text')], encrypted_content='6624c79f-a3ca-4cfe-8dcf-645e021b05b7-0', status='completed'), ResponseOutputMessage(id='c029e470-c80c-467e-ba40-82042e7ad18e', content=[ResponseOutputText(annotations=[], text="Hey! I'm doing well, thanks for asking — hope you're doing good too. What can I help you with today?", type='output_text', logprobs=[])], role='assistant', status='completed', type='message', phase='final_answer')], parallel_tool_calls=True, temperature=1.0, tool_choice='auto', tools=[], top_p=1.0, background=False, completed_at=1794032131.0, conversation=None, image=None, max_output_tokens=None, max_tool_calls=None, moderation=None, previous_response_id=None, prompt=None, prompt_cache_diagnostics=None, prompt_cache_key=None, prompt_cache_options=None, prompt_cache_retention=None, reasoning=Reasoning(context=None, effort=None, generate_summary=None, mode=None, summary=None), safety_identifier=None, service_tier='default', status='completed', text=ResponseTextConfig(format=ResponseFormatText(type='text'), verbosity=None), tool_usage=None, top_logprobs=0, truncation='disabled', usage=ResponseUsage(input_tokens=42, input_tokens_details=InputTokensDetails(cache_write_tokens=None, cached_tokens=0, cache_write_tokens_details=None), output_tokens=59, output_tokens_details=OutputTokensDetails(reasoning_tokens=32), total_tokens=101), user=None, content_filters=None, frequency_penalty=0.0, presence_penalty=0.0, store=False)
PS C:\Users\user\Desktop\从tokenizer的视角尝试判断中转站模型\script>
```

例如这个，我们能得到输入多少



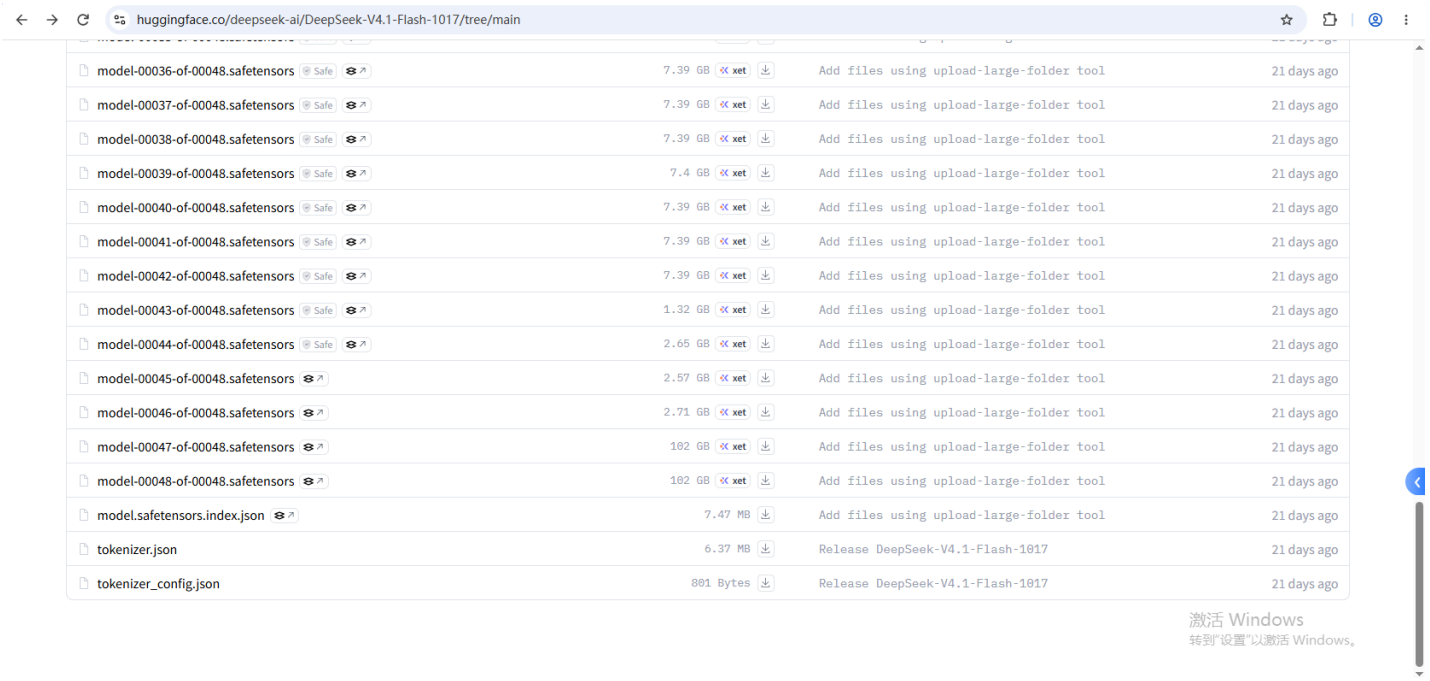
如果是空输入，默认是30tokens



我们输入1，得到input tokens是31token，说明1被tokenizer成了一个token，这样子我们就能通过调用api的形式增量计算出来内部tokenizer的结果。

构造差异

接下来我们的思路就很清晰了，去huggingface上下载tokenizer的文件，然后对比主流开源模型的tokenizer的差异，找到tokenizer差异最大的那部分来区分是什么模型。

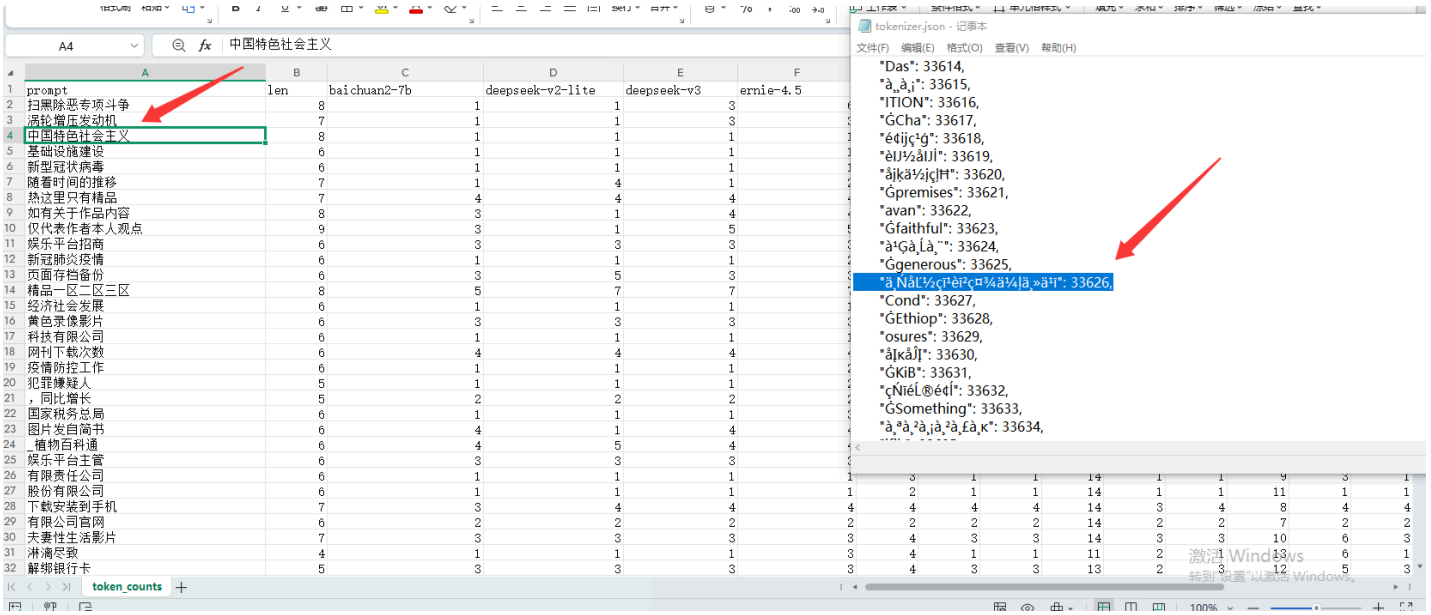


例如deepseek的tokenizer在这里可以下载

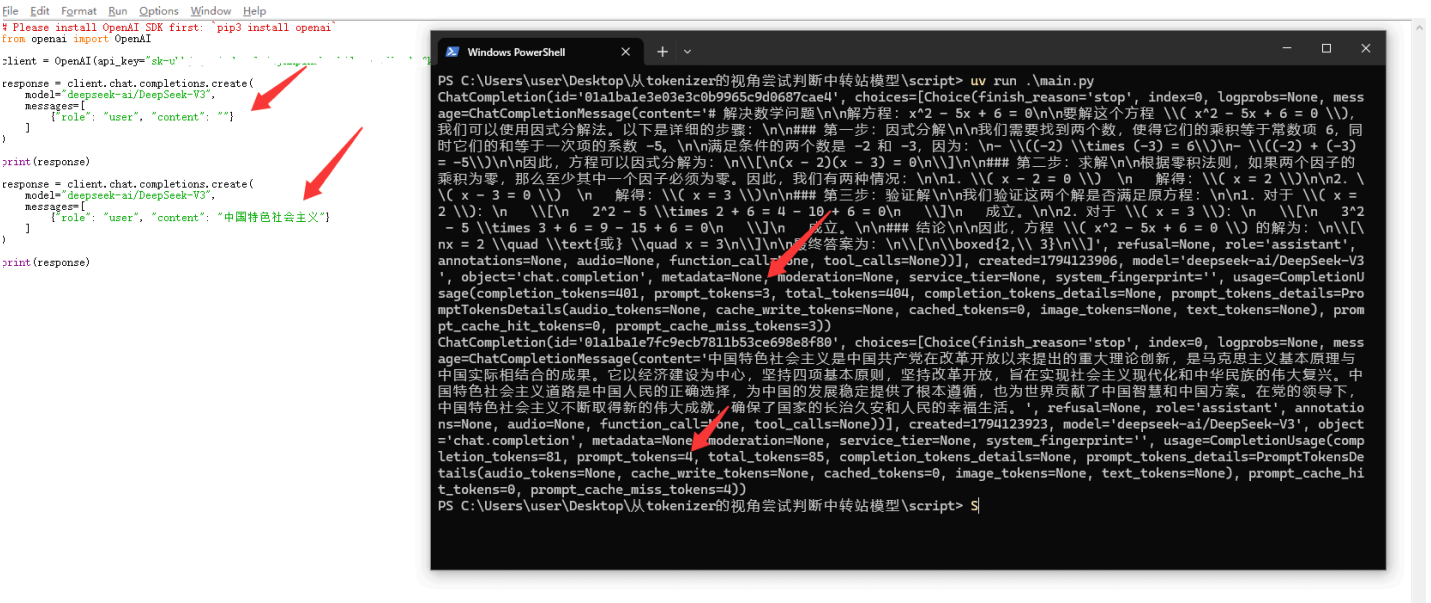


这样子我们就能看到deepseek是如何分词的了，接下来就开始尝试寻找分词差异最大的字符。

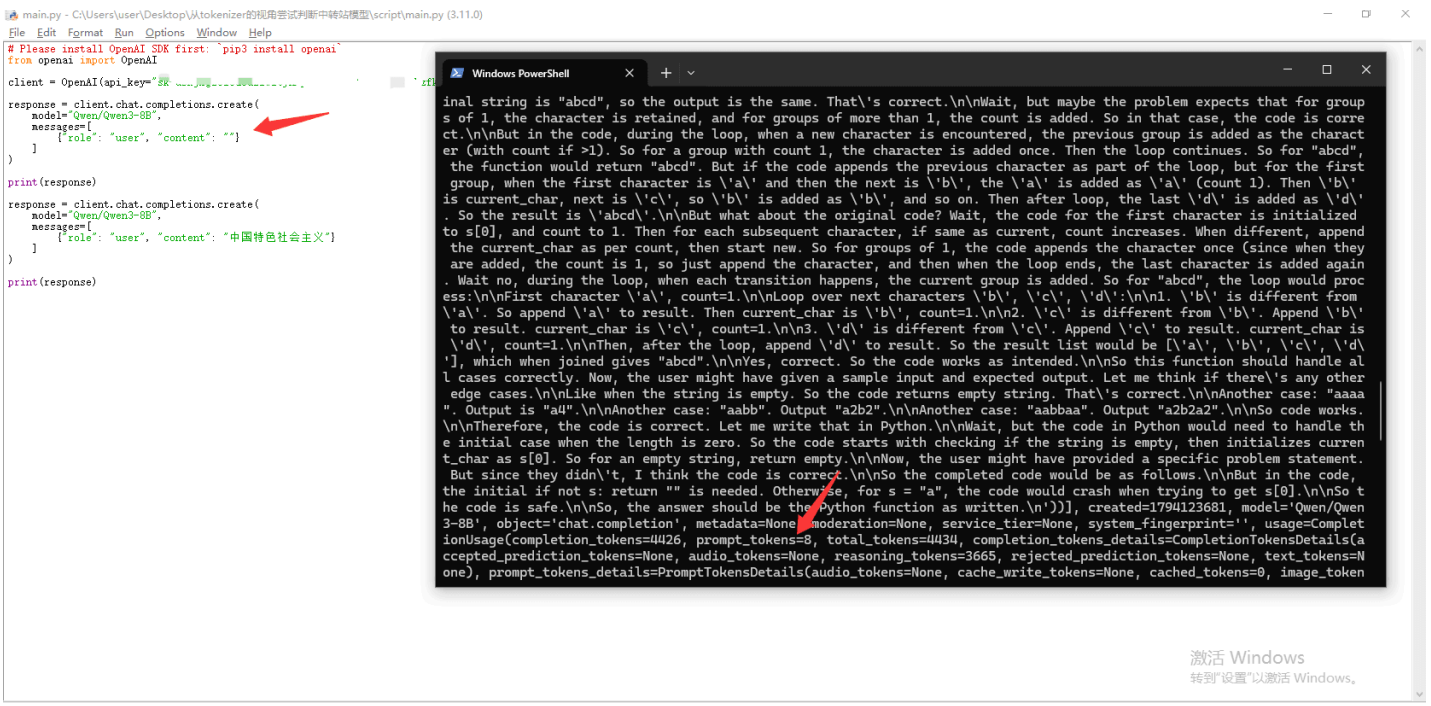
差异统计



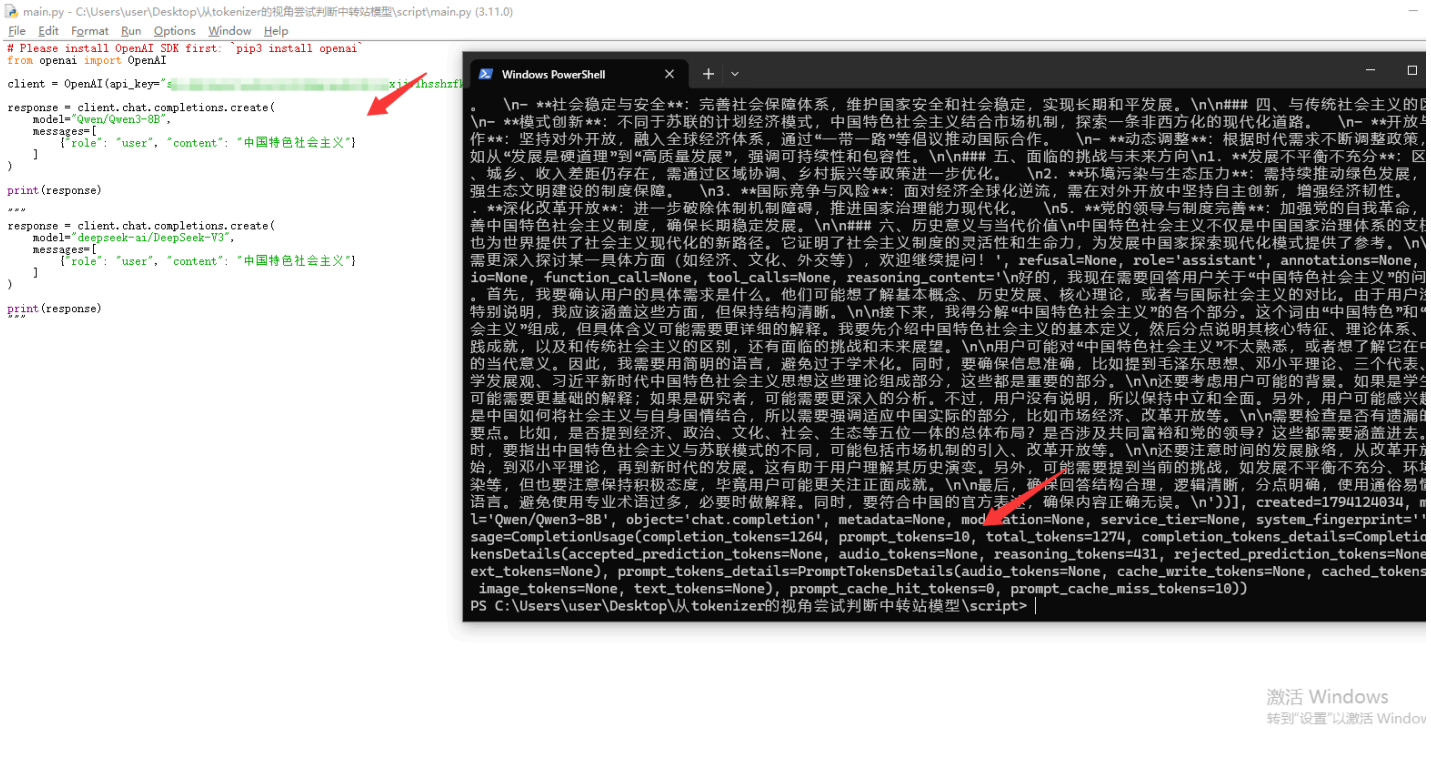
例如这种比较长但是被deepseek v3算作一个token，右边显示的是字节所以看起来是乱码，解码后就是"中国特色社会主义"



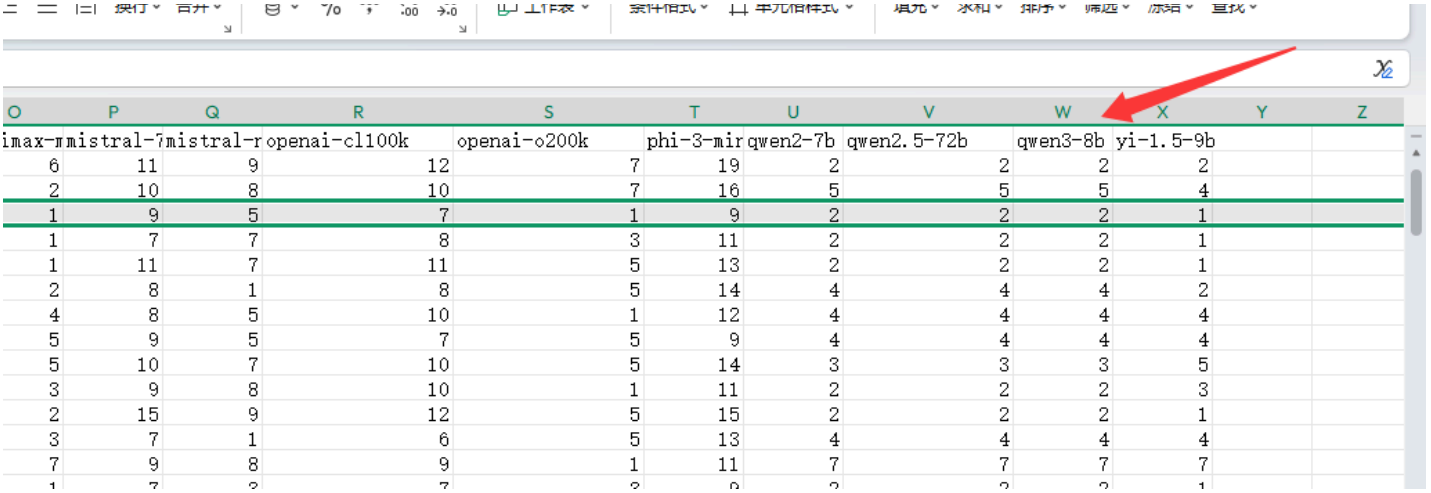
DeepSeek-V3为例子，空输入被算作3个token，加了"中国特色社会主义"，变成4个token了。说明新增的部分被算做1个token



Qwen3-8B，空输入是8 tokens



新增后就是10token了，也就是说Qwen3-8B把"中国特色社会主义"当成2个token



O	P	Q	R	S	T	U	V	W	X	Y	Z
imax-m	mistral-7	mistral-r	openai-cl100k	openai-o200k	phi-3-mir	qwen2-7b	qwen2.5-72b	qwen3-8b	yi-1.5-9b		
6	11	9	12	7	19	2	2	2	2		
2	10	8	10	7	16	5	5	5	4		
1	9	5	7	1	9	2	2	2	1		
1	7	7	8	3	11	2	2	2	1		
1	11	7	11	5	13	2	2	2	1		
2	8	1	8	5	14	4	4	4	2		
4	8	5	10	1	12	4	4	4	4		
5	9	5	7	5	9	4	4	4	4		
5	10	7	10	5	14	3	3	3	5		
3	9	8	10	1	11	2	2	2	3		
2	15	9	12	5	15	2	2	2	1		
3	7	1	6	5	13	4	4	4	4		
7	9	8	9	1	11	7	7	7	7		

和tokenizer出来的词表结果是一致的

决策树

由此我们就能想决策数一样，在词表中找出一些差异，例如某一段prompt ABC模型算作1个token，EFG模型算作2个token，于是乎我们就能派出ABC模型的可能，然后进一步在EFG中构造差异来分出属于哪个家族的模型。

局限性

这个只能是用来判断的其中一种特征，并且闭源模型的tokenizer还要自己买api自己请求记录。如果tokenizer的角度符合也只能说明是同一个家族的，不能说明没有量化或者替换同家族。但是如果tokenizer出来的词表都不符合，那一定就是假的。